

Identificador de Fake News

Caio Cesar Navarro Pugliese (10436413)¹, Enzo Maranhão Tucilho (10436106)¹

¹ Faculdade de Computação e Informática – Universidade Presbiteriana Mackenzie
(MACK)

São Paulo – SP – Brasil

caiocesar.np@hotmail.com, enzomt2006@gmail.com

Resumo

A disseminação de desinformação na internet dificulta o acesso a informações confiáveis, especialmente diante do grande volume de conteúdos compartilhados diariamente. Este projeto propõe o desenvolvimento de uma aplicação baseada em Inteligência Artificial para auxiliar na identificação de notícias potencialmente falsas. A solução será direcionada a notícias em português e utilizará técnicas de Processamento de Linguagem Natural (PLN) e Aprendizado de Máquina para analisar os textos e identificar padrões presentes nos dados. Será utilizado o Fake.Br Corpus como base para treinamento e avaliação dos modelos. A metodologia envolverá análise exploratória, preparação dos textos, representação utilizando TF-IDF, treinamento e comparação de modelos de classificação e desenvolvimento de um protótipo funcional. Como resultado, espera-se obter uma ferramenta de apoio capaz de apresentar uma estimativa sobre a possível associação de uma notícia com conteúdo falsos, sem tratar a classificação como uma confirmação definitiva.

Introdução

Contextualização

A internet e as redes sociais possibilitaram a produção e o compartilhamento de informações em grande escala. Apesar dos benefícios proporcionados pela facilidade de acesso a conteúdos, esse cenário também favorece a circulação de informações falsas.

A identificação manual desses conteúdos pode ser dificultada pelo grande volume de informações disponíveis. Nesse contexto, técnicas de Inteligência Artificial podem ser utilizadas para auxiliar na análise automatizada de textos e na identificação de padrões relacionados à desinformação.

O projeto Identificador de Fake News será delimitado à análise de notícias textuais em português brasileiro, utilizando uma base de dados previamente rotulada. A proposta consiste em desenvolver uma aplicação capaz de receber o texto de uma notícia e gerar uma estimativa sobre sua possível associação com conteúdos potencialmente falsos ou verdadeiros, com base nos padrões aprendidos pelos modelos.

Justificativa

O uso de Inteligência Artificial pode auxiliar na análise de grandes volumes de notícias, reduzindo a necessidade de análise manual de cada conteúdo. Técnicas de Processamento de Linguagem Natural permitem transformar textos em representações que podem ser utilizadas por algoritmos de Aprendizado de Máquina para identificar padrões presentes nos dados.

Dessa forma, o projeto busca explorar a aplicação dessas técnicas em um problema real, utilizando uma base de notícias em português e desenvolvendo uma solução capaz de apoiar a análise inicial de conteúdos informativos.

Motivação

A circulação de desinformação pode dificultar a identificação de informações confiáveis pelos usuários. A motivação do projeto está na possibilidade de utilizar técnicas de Inteligência Artificial para desenvolver uma ferramenta de apoio à análise de notícias, contribuindo para que os usuários possam realizar uma avaliação inicial de determinados conteúdos.

O projeto também está relacionado ao ODS 16 – Paz, Justiça e Instituições Eficazes, especialmente à meta 16.10, relacionada ao acesso público à informação.

Objetivo

Desenvolver um protótipo funcional baseado em Inteligência Artificial capaz de receber o texto de uma notícia em português e gerar uma estimativa sobre sua possível

associação com conteúdos potencialmente falsos ou verdadeiros, utilizando técnicas de Processamento de Linguagem Natural e Aprendizado de Máquina.

Para isso, serão analisados diferentes modelos de classificação, buscando comparar seus desempenhos por meio de métricas apropriadas e selecionar uma abordagem para o protótipo.

Contribuições esperadas

Espera-se desenvolver um protótipo funcional para análise de notícias em português, além de avaliar e comparar diferentes modelos de Aprendizado de Máquina aplicados à classificação de textos.

Também se espera demonstrar a aplicação de técnicas de PLN e Aprendizado de Máquina em um problema real relacionado à desinformação, considerando as limitações e os possíveis erros dos modelos utilizados.

Fundamentação Teórica

Conceitos fundamentais

Inteligência Artificial

A Inteligência Artificial engloba técnicas computacionais utilizadas para desenvolver sistemas capazes de realizar tarefas que envolvem análise de dados, identificação de padrões e tomada de decisões baseada em informações disponíveis.

Neste projeto, técnicas de Inteligência Artificial serão utilizadas para identificar padrões presentes em notícias previamente classificadas e utilizar esses padrões na análise de novos textos.

Aprendizado de Máquina

O Aprendizado de Máquina é uma área da Inteligência Artificial que utiliza algoritmos capazes de aprender padrões a partir de dados.

O projeto utilizará Aprendizado de Máquina supervisionado, pois os dados utilizados para treinamento possuem classes previamente definidas. Dessa forma, os modelos poderão aprender características associadas às diferentes classes e posteriormente realizar estimativas sobre novos textos.

Processamento de Linguagem Natural

O Processamento de Linguagem Natural (PLN) reúne técnicas destinadas ao processamento computacional de textos escritos em linguagem humana.

No projeto, o PLN será utilizado nas etapas de preparação e transformação das notícias, permitindo que os textos sejam representados de forma adequada para utilização nos modelos de Aprendizado de Máquina.

Classificação de textos

A classificação de textos consiste em atribuir uma categoria a determinado conteúdo textual com base nas características identificadas durante o treinamento do modelo.

Neste projeto, a classificação será realizada utilizando notícias previamente rotuladas, permitindo que os modelos aprendam padrões associados às diferentes classes presentes no dataset.

TF-IDF

Para utilizar textos em modelos de Aprendizado de Máquina, é necessário transformá-los em uma representação numérica. Uma das técnicas consideradas neste projeto é o TF-IDF (Term Frequency-Inverse Document Frequency).

Essa técnica permite representar os documentos considerando a frequência dos termos e sua relevância dentro do conjunto de documentos. Dessa forma, os textos podem ser convertidos em vetores numéricos utilizados pelos algoritmos de classificação.

Trabalhos relacionados

Khanam et al. (2021) apresentam uma abordagem para detecção de fake news utilizando Aprendizado de Máquina supervisionado e Processamento de Linguagem Natural. O trabalho explora técnicas de processamento e representação textual, incluindo métodos de vetorização como Count Vectorizer e TF-IDF, além de técnicas de seleção de características. Os autores utilizam modelos de aprendizado de máquina e analisam seu desempenho por meio de métricas e matriz de confusão. A abordagem apresentada possui relação direta com o presente projeto, pela utilização de PLN, representação numérica dos textos e modelos supervisionados para classificação de notícias.

Sharma, Saran e Patil (2021) propõem uma solução para classificação de notícias como falsas ou reais utilizando conceitos de Inteligência Artificial, Processamento de Linguagem Natural e Machine Learning. O trabalho investiga diferentes técnicas de representação dos textos e algoritmos de classificação, buscando desenvolver uma abordagem para a detecção de fake news. A proposta também considera a utilização de uma aplicação para que o usuário possa realizar a classificação de notícias. Esse trabalho se aproxima da proposta do projeto por combinar preparação textual, representação dos dados e diferentes modelos de classificação para desenvolver uma solução de apoio ao usuário.

Ahmad et al. (2020) investigam a utilização de métodos de ensemble para a classificação automática de notícias potencialmente falsas. Os autores analisam diferentes características textuais e treinam combinações de algoritmos de Machine

Learning, avaliando as abordagens em quatro conjuntos de dados reais. Os resultados apresentados indicam desempenho superior da abordagem de ensemble em comparação com os modelos individuais avaliados pelos autores. Esse trabalho é relevante para o presente projeto por demonstrar a importância da comparação entre diferentes modelos e estratégias de classificação. Embora a proposta atual não tenha como objetivo inicial utilizar métodos de ensemble, a comparação de diferentes algoritmos será utilizada para avaliar qual abordagem apresenta melhor desempenho para o dataset selecionado.

A análise dos trabalhos relacionados demonstra a utilização de diferentes técnicas de Processamento de Linguagem Natural e Aprendizado de Máquina na classificação de fake news. A partir dessas abordagens, o presente projeto adotará uma estratégia baseada na representação dos textos por TF-IDF e na comparação de diferentes modelos de classificação. Como delimitação, a proposta será direcionada a notícias textuais em português brasileiro e utilizará o Fake.Br Corpus como base para treinamento e avaliação. Além disso, será desenvolvido um protótipo funcional destinado a apresentar uma estimativa sobre a possível associação de uma notícia com conteúdos potencialmente falsos.

Metodologia e Resultados Esperados

Abordagem proposta

O desenvolvimento da solução será dividido em etapas, desde a preparação da base de dados até o desenvolvimento do protótipo.

Inicialmente, será realizada uma análise exploratória do dataset para compreender sua estrutura e características. Em seguida, os textos serão preparados para utilização nos modelos, realizando as operações necessárias de limpeza e normalização.

Após a preparação, os textos serão transformados em representações numéricas utilizando TF-IDF. Essas representações serão utilizadas no treinamento dos modelos de classificação.

Serão avaliados diferentes algoritmos de Aprendizado de Máquina, tendo como modelos candidatos Naive Bayes, Regressão Logística e Random Forest. A utilização de mais de um modelo permitirá comparar diferentes abordagens para o problema.

Os dados serão divididos entre conjuntos de treinamento e teste, de forma a avaliar a capacidade dos modelos de realizar classificações em textos que não foram utilizados durante o treinamento.

A avaliação será realizada utilizando métricas como Accuracy, Precision, Recall e F1-score. Os resultados serão comparados para analisar o desempenho dos modelos.

Por fim, será desenvolvido um protótipo funcional no qual o usuário poderá inserir o texto de uma notícia e receber a estimativa produzida pelo modelo.

Dataset

O dataset selecionado para o desenvolvimento do projeto é o Fake.Br Corpus, um corpus composto por notícias falsas e verdadeiras escritas em português. A base foi desenvolvida para pesquisas relacionadas à detecção automática de fake news e ao Processamento de Linguagem Natural.

O corpus possui 7.200 notícias, sendo 3.600 classificadas como verdadeiras e 3.600 como falsas, formando um conjunto balanceado entre as duas classes. As notícias foram coletadas entre janeiro de 2016 e janeiro de 2018. A base contempla diferentes categorias de notícias, incluindo política, televisão e celebridades, sociedade e notícias diárias, ciência e tecnologia, economia e religião.

Os dados são disponibilizados em formato de texto e possuem versões distintas no repositório oficial. A versão `full_texts` contém os textos completos das notícias, separados entre as classes `fake` e `true`, além de arquivos com informações de metadados. Entre os metadados disponíveis estão autor, link, categoria, data de publicação, quantidade de palavras, quantidade de tokens, quantidade de verbos, substantivos, adjetivos, advérbios, pronomes, tamanho médio das frases e palavras, entre outras características.

O corpus também disponibiliza uma versão denominada `size_normalized_texts`, na qual os textos de cada par de notícias falsas e verdadeiras são ajustados para que possuam tamanhos semelhantes. Também existe uma versão `preprocessed`, que contém textos previamente processados.

Para o projeto, será realizada inicialmente uma análise da versão dos dados escolhida, verificando a distribuição das classes, quantidade e tamanho dos textos, presença de valores ausentes ou inconsistentes, possíveis duplicações e características gerais das notícias.

Análise exploratória dos dados

Inicialmente, foi realizada uma análise exploratória do conjunto de dados. A primeira análise considerou a distribuição das notícias entre as classes `fake` e `true`.




Figura 1 – Distribuição das classes do conjunto de dados.
Fonte: Elaborado pelos autores com base no Fake.Br Corpus.

A análise da distribuição das classes permite verificar o equilíbrio entre as categorias utilizadas no problema de classificação. O conjunto apresenta 3600 notícias classificadas como fake e 3600 classificadas como true, totalizando 7200 notícias analisadas.

Também foi analisada a distribuição das notícias de acordo com suas categorias.




Figura 2 – Distribuição das notícias por categoria.

Fonte: Elaborado pelos autores com base no Fake.Br Corpus.

As categorias identificadas no conjunto de dados são política, TV e celebridades, sociedade e cotidiano, ciência e tecnologia, economia e religião. Essa distribuição permite observar a composição temática do conjunto utilizado no treinamento dos modelos.

Também foi realizada uma análise conjunta entre as categorias e as classes das notícias.




Figura 3 – Distribuição das categorias de acordo com a classe.
Fonte: Elaborado pelos autores com base no Fake.Br Corpus.

Essa análise permite observar como as classes fake e true estão distribuídas entre os diferentes temas presentes no dataset, contribuindo para a compreensão da composição dos dados utilizados na classificação.

Outra característica analisada foi a quantidade de palavras presente nas notícias. Para isso, foi calculada a quantidade de palavras de cada texto e posteriormente obtida a média por classe.




Figura 4 – Média de palavras por notícia de acordo com a classe.

Fonte: Elaborado pelos autores com base no Fake.Br Corpus.

A média de palavras foi de aproximadamente 185 palavras nas notícias classificadas como fake e 1100 palavras nas notícias classificadas como true. Essa análise permite observar uma característica estrutural dos textos antes da aplicação dos métodos de representação e classificação.

Também foram verificadas a existência de valores ausentes e a ocorrência de textos duplicados. Foi identificado 1 texto duplicado. Quanto aos valores ausentes, não identificamos valores ausentes nas informações utilizadas na análise, ou seja, não será necessária a realização de procedimentos para preenchimento ou remoção desses registros.

Por fim, foi realizada uma análise das palavras mais frequentes presentes nos textos, após a remoção de elementos como URLs, números, palavras com apenas um caractere e termos considerados stopwords.




Figura 5 – Vinte palavras mais frequentes no conjunto de dados após a etapa inicial de limpeza.

Fonte: Elaborado pelos autores com base no Fake.Br Corpus.

A análise das palavras mais frequentes permite caracterizar inicialmente o vocabulário presente nas notícias e auxilia na identificação de padrões linguísticos existentes no conjunto de dados.

Também foi analisada a frequência das palavras separadamente entre as classes true e fake. A análise permite observar a distribuição dos termos utilizados em cada classe e identificar possíveis padrões presentes nos textos.




Figura 6 – 20 palavras mais frequentes nas notícias verdadeiras.

Fonte: Elaborado pelos autores com base no Fake.Br Corpus.




Figura 7 – 20 palavras mais frequentes nas notícias falsas.

Fonte: Elaborado pelos autores com base no Fake.Br Corpus.

Preparação dos dados

Após a análise exploratória, os textos serão preparados para utilização nos modelos de Aprendizado de Máquina. Essa etapa poderá envolver limpeza dos conteúdos, normalização textual e remoção de elementos que não contribuam para a classificação.

Em seguida, os textos serão transformados em uma representação numérica utilizando TF-IDF (Term Frequency-Inverse Document Frequency).

Os dados serão posteriormente separados em conjuntos de treinamento e teste. O conjunto de treinamento será utilizado para aprendizado dos modelos, enquanto o conjunto de teste será reservado para avaliar seu desempenho em notícias que não foram utilizadas durante o treinamento.

A preparação dos dados será realizada de forma a evitar que informações do conjunto de teste sejam utilizadas durante o treinamento, reduzindo o risco de resultados artificialmente elevados.

Modelos e avaliação

Serão considerados inicialmente três algoritmos de classificação: Naive Bayes, utilizado como uma abordagem de referência para classificação de textos; Regressão Logística, utilizada como modelo de classificação supervisionada; Random Forest, utilizada para comparação com uma abordagem baseada em conjuntos de árvores de decisão. Os modelos serão comparados utilizando Accuracy, Precision, Recall e F1-score.

A comparação permitirá verificar como diferentes algoritmos se comportam diante da mesma representação dos textos e identificar a abordagem mais adequada para a implementação do protótipo, com base nos resultados experimentais.

Resultados esperados

Espera-se obter modelos capazes de identificar padrões presentes nas notícias do dataset e utilizar esses padrões para produzir estimativas sobre novos textos.

Também se espera identificar diferenças de desempenho entre os modelos avaliados e desenvolver um protótipo funcional capaz de receber o texto de uma notícia e apresentar sua classificação estimada.

O resultado deverá ser apresentado como uma estimativa baseada nos padrões aprendidos pelo modelo, e não como uma confirmação definitiva sobre a veracidade de uma notícia.

Resultados Parciais

Aspectos éticos e responsabilidade no desenvolvimento da solução

O uso de Inteligência Artificial para classificação de notícias envolve questões éticas relacionadas principalmente aos possíveis erros e vieses presentes nos dados e nos modelos.

Uma classificação incorreta pode levar um usuário a interpretar uma informação como falsa ou verdadeira de maneira inadequada. Por esse motivo, o sistema será apresentado como uma ferramenta de apoio e não como um mecanismo definitivo de verificação da veracidade das informações.

Também será necessário avaliar a procedência e as condições de uso do dataset, além de verificar a possível presença de informações pessoais nos conteúdos. Quando necessário, deverão ser adotadas medidas para minimizar a exposição de dados pessoais.

Resultados parciais obtidos

Nesta etapa, foi implementada e executada a análise exploratória completa da base de dados, permitindo caracterizar tecnicamente o corpus antes da etapa de treinamento dos modelos.

A análise confirmou o equilíbrio entre as classes do dataset, com 3.600 notícias fake e 3.600 notícias true, o que reduz a necessidade de técnicas de balanceamento na etapa de modelagem. Também foi identificado um forte desequilíbrio estrutural entre as classes quanto ao tamanho dos textos: as notícias falsas possuem, em média, aproximadamente 185 palavras, enquanto as notícias verdadeiras possuem em média 1.100 palavras. Essa diferença é relevante para o projeto, pois um modelo de classificação pode aprender a associar textos curtos à classe fake e textos longos à classe true com base apenas no tamanho do documento, e não necessariamente em padrões linguísticos de desinformação. Esse ponto será considerado na etapa de preparação dos dados e na interpretação dos resultados dos modelos, podendo ser necessário avaliar o desempenho dos classificadores de forma independente do comprimento dos textos.

Foi identificada ainda a existência de 1 texto duplicado no conjunto de dados, que deverá ser tratado na etapa de preparação, e não foram identificados valores ausentes. A análise de frequência de palavras, realizada separadamente para cada classe, evidenciou vocabulário parcialmente distinto entre notícias fake e true, o que reforça a hipótese de que existem padrões lexicais capturáveis pela representação TF-IDF a ser utilizada na etapa de classificação.

Como próxima etapa, será realizada a preparação definitiva dos textos, a geração da representação TF-IDF e o treinamento dos modelos de classificação, conforme descrito na metodologia.

GitHub

Repositório: <https://github.com/CaioC74/Identificador-de-Fake-News>

O repositório está sendo utilizado para armazenar os códigos, notebooks, documentação, análises e demais arquivos relacionados ao desenvolvimento do projeto.

Referências

Trabalhos relacionados

Khanam, Z., Alwasel, B. N., El-Zaart, A. and Jasser, M. (2021) “Fake News Detection Using Machine Learning Approaches”, **IOP Conference Series: Materials Science and Engineering**, Vol. 1099, No. 1, 012040.

Sharma, S., Saran, S. and Patil, S. (2021) “Fake News Detection using Machine Learning Algorithms”, **International Journal of Engineering Research & Technology**, Vol. 9, No. 3.

Ahmad, I., Yousaf, M., Yousaf, S. and Ahmad, M. O. (2020) “Fake News Detection Using Machine Learning Ensemble Methods”, **Complexity**, Vol. 2020, Article ID 8885861.

Dataset

Fake.Br Corpus. Repositório oficial do corpus de notícias falsas e verdadeiras em português brasileiro.

Monteiro R.A., Santos R.L.S., Pardo T.A.S., de Almeida T.A., Ruiz E.E.S., Vale O.A. (2018) Contributions to the Study of Fake News in Portuguese: New Corpus and Automatic Detection Results. In: Villavicencio A. et al. (eds) Computational Processing of the Portuguese Language. PROPOR 2018. Lecture Notes in Computer Science, vol 11122. Springer, Cham